

Contents

MetaX-TrustClaw 技术文档	1
1. 系统架构	1
2. 推理引擎	2
3. 推理效果	2
4. TrustClaw / OpenClaw	2
5. 复现	2

MetaX-TrustClaw 技术文档

第八届 **CCF** 开源创新大赛·国产开源 **GPU AI** 创新生态赛·初赛提交材料

战队： YiRage ·队长：陈星强·单位：厦门大学

GitLink: gitlink.org.cn/xingjian/metaX-inference ·gitlink.org.cn/xingjian/trustclaw

1. 系统架构

1.1 三层架构

层级	组件	职责
应用层	TrustClaw Gateway + trustclaw-tra	Agent Pack、证据链、TRA Console
推理层	vLLM + vllm_metax + metax_kernels	Qwen3.6 本地推理、OpenAI 兼容 API
算力层	MetaX MACA C500	AWQ GEMM、Flash Attention

1.2 请求链路

1. 用户通过 TRA Console 发起对话
2. POST /api/agent/chat 进入 trustclaw-tra 审计 pipeline
3. Agent Pack 访问本地 SQLite (trustclaw_tra_query/write)
4. LLM 请求转发至本地 vLLM <http://vllm:8000/v1> (沐曦 GPU)
5. 响应与 evidence 写入 audit log

合规：不调用 OpenAI / Anthropic 等外部云端 API。

1.3 Docker 部署

镜像	端口	说明
metax-vllm:local	8000	vLLM 推理
metax-trustclaw:local	19001	TrustClaw Gateway

镜像	端口	说明
metax-openclaw:local	—	TRA UI 基础镜像

2. 推理引擎

组件	版本
GPU	MetaX C500, 32GB sGPU
MACA	3.5.3.20
vLLM	0.17.0 + vllm_metax
模型	Qwen3.6-27B-AWQ INT4

自研模块: fused_rope_rms、gqa_attention、awq_gemm、fused_mlp、vllm_metax_plugin

3. 推理效果

指标	实测
单请求 tok/s	31.85
并发 c=8 tok/s	81.02
MTP 等效 tok/s	23.65
并发 c=18 tok/s	155.89
TTFT	0.08s

4. TrustClaw / OpenClaw

TrustClaw 基于 OpenClaw fork, 新增 TRA 五平面: Data · Policy · Agent · Evidence · Operator

核心 API: /api/tra/init、/api/agent/chat、trustclaw_tra_query、trustclaw_tra_write

vLLM 配置: configs/trustclaw-metax-vllm.json

5. 复现

```
./scripts/test-env-check.sh
./scripts/serve_qwen36_metax.sh
./scripts/deploy_trustclaw_metax.sh
python scripts/bench_acceptance.py . --markdown
```

YiRage · 厦门大学 · 陈星强 · 2026-07-10