

Contents

MetaX-TrustClaw 性能测试报告1

1. 测试环境

2. 分阶段验收

3. Phase 0 调参

4. Phase 1 并发

5. 算子 benchmark (S=256)

6. 合规声明

1

1

1

2

2

2

MetaX-TrustClaw 性能测试报告

第八届 CCF 开源创新大赛·国产开源 GPU AI 创新生态赛

战队： YiRage ·队长： 陈星强·单位： 厦门大学
测试日期： 2026-07-06 ~ 2026-07-07

1. 测试环境

项目	值
GPU	MetaX C500, 32GB sGPU, 50% 算力配额
MACA	3.5.3.20
vLLM	0.17.0 + vllm_metax
模型	Qwen3.6-27B-AWQ INT4

2. 分阶段验收

阶段	指标	目标	实测	状态
Phase 0	单请求 tok/s	9.5	31.85	PASS
Phase 1	并发 c=8 tok/s	40	81.02	PASS
Phase 2	fused_rope ms	0.5	0.525	接近
Phase 3	MTP tok/s	20	23.65	PASS
C8160	c=18 tok/s	~160	155.89	接近

3. Phase 0 调参

配置	tok/s	TTFT
t0.7 + thinking	7.50	13.0s
t0 无 thinking	31.85	0.08s

4. Phase 1 并发

配置	c8 tok/s
默认	39.78
t0 调优	81.02

5. 算子 benchmark (S=256)

Kernel	ms
fused_rope_rms	0.525
gqa_attention:sdpa	0.12
gqa_attention:fused	0.16

6. 合规声明

- 全部数据在沐曦 MetaX C500 实机采集
- 本地 vLLM 推理, 未调用外部云端 API
- 详见仓库 TEST_RESULTS.md

YiRage · 厦门大学 · 陈星强 · **2026-07-10**